

Introducción y Ciclo de Vida de la Ciencia de Datos

Fundamentos de
Ciencia de Datos

Germán A. Montoya O.
gamontoyao@eafit.edu.co

Universidad EAFIT

Medellín 2026

Definición

- Es la disciplina que permite transformar grandes volúmenes de datos en conocimiento accionable para impulsar la toma de decisiones estratégicas.



Definición

- Ejemplos:
 - En plataformas de streaming:
 - Segmentar tipos de usuarios.
 - Predecir posible fuga de usuarios.
 - Recomendar películas o series.




Definición

- Ejemplos:
 - En redes sociales:
 - Análisis de sentimientos.
 - Recomendación de nuevos amigos.
 - Recomendar contenidos en Instagram, TikTok.
 - Transporte y Logística:
 - Mantenimiento predictivo
 - Gestión del tráfico




Definición

- Ejemplos:
 - En salud y medicina:
 - Apoyo en diagnóstico de enfermedades.
 - En deportes:
 - Análisis del rendimiento de deportistas, estrategias de juego y prevención de lesiones.
 - En ciberseguridad:
 - Identificación de ciberamenazas.



Naturaleza Interdisciplinaria de la Ciencia de Datos



Fuente: <https://www.create-learn.us/blog/data-science-for-children/>

Naturaleza Interdisciplinaria de la Ciencia de Datos

- Matemáticas y Estadística:
 - Álgebra Lineal
 - Cálculo
 - Probabilidad
 - Analisis descriptivo, inferencial, predictivo y prescriptivo.
- Informática:
 - Bases de datos
 - Procesar y manipular datos
 - Desarrollo e implementación de algoritmos y modelos
 - Despliegue y mantenimiento de soluciones
 - Seguridad

Naturaleza Interdisciplinaria de la Ciencia de Datos

- Experiencia empresarial y en el área de aplicación:
 - Formulación del problema
 - Adquisición y comprensión de datos relevantes
 - Interpretación y comunicación de resultados

Historia

- Siglo XX:
 - 1946: Surge la 1ra computadora electrónica digital de propósito general (ENIAC).
 - 1956: Nacimiento formal del término Inteligencia Artificial (John McCarthy)
 - Conferencia de Dartmouth
 - 1962: Artículo “The Future of Data Analysis” (John W. Tukey)
 - Enfoque práctico.



Fuente: <https://emeritus.org/in/learn/what-is-artificial-intelligence/>

Historia

- Siglo XX:
 - 1974: Nacimiento del término “**Data Science**” (Pater Naur).
 - Libro: "Concise Survey of Computer Methods"
 - 1989: Primer taller sobre "Knowledge Discovery in Databases (KDD)" (minería de datos).
 - 1990: Proliferación de Algoritmos.
 - Árboles de decisión, SVM, Redes Neuronales (retropropagación).
 - 1997: IBM Deep Blue derrota a Kasparov.




Fuente: <https://www.bigdatawire.com/2017/08/31/continuing-data-science-education/>



Fuente: <https://datascientest.com/en/all-about-deep-blue>

Historia

- Siglo XXI:
 - 2001: La Ciencia de Datos como disciplina independiente.
 - Estadística + Computación.
 - 2006 – 2009: Auge del “Big Data” gracias a Google, Amazon y Yahoo!.
 - 2008: El "**Científico de Datos**" nace formalmente.
 - D.J. Patil (LinkedIn) y Jeff Hammerbacher (Facebook).



Fuente: <https://www.create-learn.us/blog/data-science-for-children/>

Historia

- Siglo XXI:
 - 2010: Democratización y expansión.
 - Popularización del diagrama “maths & stats + informatics + business knowledge” (Drew Conway).
 - Ciencia de Datos → Profesión mas sexy del siglo XXI.
 - Popularización de Python + librerías para ciencia de datos.
 - Resurgimiento del Aprendizaje Profundo (Deep Learning) gracias a:
 - Aumento de capacidad computacional (GPUs).
 - Disponibilidad de grandes conjuntos de datos.



Fuente: <https://www.create-learn.us/blog/data-science-for-children/>

Futuro dentro de 10 años

- Hiper-Automatización en tareas rutinarias de la ciencia de datos.
- Mas apoyo de la IA generativa en generación de código, explicación de modelos complejos y asistencia en exploración de datos.
- Democratización de la Ciencia de Datos.
- Mayor foco en la ética y explicabilidad de la IA.
- Análisis en Tiempo Real y Edge Computing.
- Actualización constante.



Fuente: <https://sloanreview.mit.edu/article/changing-culture-is-central-to-changing-business-models/>

Ciclo de vida de la Ciencia de Datos: CRISP-DM

Fase del Ciclo de Vida	Objetivo Principal	Actividades Clave
1. Comprensión del Negocio	Definir el problema y los objetivos del negocio que los datos pueden resolver.	Entender requisitos, establecer métricas de éxito, evaluar viabilidad.
2. Comprensión de los Datos	Explorar y evaluar la calidad y relevancia de los datos disponibles.	Recopilar datos iniciales, descripción de datos (EDA), verificación de calidad.
3. Preparación de los Datos	Limpiar, transformar y organizar los datos para el modelado.	Manejo de valores faltantes/outliers, transformación, ingeniería y selección de características.
4. Modelado	Seleccionar y aplicar algoritmos para construir el modelo.	Elegir algoritmo, dividir datos, entrenar modelo, ajustar hiperparámetros.
5. Evaluación del Modelo	Determinar la calidad, precisión y utilidad del modelo.	Calcular métricas de rendimiento, validación cruzada, interpretar resultados, revisión con negocio.
6. Despliegue y Monitoreo	Poner el modelo en producción y asegurar su funcionamiento continuo.	Implementar el modelo, monitorear rendimiento, mantenimiento y reentrenamiento.

Este ciclo de vida sigue la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining).

Ciclo de vida de la Ciencia de Datos

OSEMN

Fase de OSEMN	Objetivo Principal	Actividades Clave
Obtain (Obtener)	Adquirir los datos relevantes para el problema.	Identificar fuentes de datos, extraer datos, integrar de múltiples orígenes.
Scrub (Limpiar)	Preparar y limpiar los datos para el análisis y el modelado.	Manejar valores faltantes/outliers, corregir errores, ingeniería de características.
Explore (Explorar)	Comprender patrones y generar hipótesis con análisis exploratorio.	Estadísticas descriptivas, visualizaciones (EDA), identificar relaciones.
Model (Modelar)	Construir un modelo predictivo o de inferencia.	Seleccionar algoritmo, entrenar y ajustar el modelo, evaluar su rendimiento.
Narrate (Narrar)	Comunicar los hallazgos y recomendaciones de forma efectiva.	Visualizar resultados, crear informes, contar una historia, recomendar acciones.



Fuente: <https://datasciencedojo.com/blog/understanding-applied-data-science/>


Ciclo de vida de la Ciencia de Datos: Metodologías adicionales

- **KDD (Knowledge Discovery in Databases):** descubrimiento de conocimiento a partir de bases de datos.



Fuente: <https://stock.adobe.com/es/images/>

- **Metodologías Ágiles:**
 - SCRUM
 - Kanban



Fuente: <https://www.cognodata.com/blog/principios-metodologia-agile-desarrollo-proyectos/>

Ciclo de vida de la Ciencia de Datos: Metodologías adicionales

- **Metodologías Ágiles:**
 - **SCRUM**
 - Gestión de proyectos de forma iterativa e incremental.
 - Ciclos de trabajo cortos y fijos llamados "Sprints" (generalmente de 1 a 4 semanas)
 - Roles clave:
 - **Product owner:** voz del cliente, define funcionalidades a construir.
 - **Scrum Master:** verifica que el equipo cumpla con las funcionalidades.
 - **Scrum Team:** El equipo que desarrolla el producto.
 - Eventos clave:
 - **Sprint Planning:** lo que debe entregar el sprint.
 - **Daily Scrum:** reunión diaria para revisar avances y retroalimentación.
 - **Sprint Review:** Demostración del incremento de producto a los stakeholders.

Ciclo de vida de la Ciencia de Datos: Metodologías adicionales

- **Metodologías Ágiles:**
 - **Kanban**
 - Tablero visual con columnas "Pendiente", "En Progreso", "Terminado" por cada tarea.
 - Tarjetas kanban: Representan las tareas individuales.

Ciclo de vida de la Ciencia de Datos: Cual es la mejor?


- **CRISP-DM:** Para proyectos empresariales bien estructurados, complejos y a gran escala.
- **OSEMN:** Para proyectos más pequeños, exploración rápida o para entender el flujo básico de trabajo.
- **KDD:** Para un enfoque en la investigación y el descubrimiento de conocimiento.
- **Metodologías Ágiles:** Cuando la flexibilidad, la adaptación y la entrega incremental son prioritarias.
- Hoy en día → **enfoque híbrido**
 - CRISP-DM: estructura y alineación con el negocio.
 - OSEMN: guía para tareas técnicas.
 - Metodologías Ágiles: gestión diaria e iteraciones.



Fuente: <https://sloanreview.mit.edu/article/getting-serious-about-data-and-data-science/>

Roles Clave del Científico de Datos

Rol	Enfoque Principal	Responsabilidades Clave	Habilidades Típicas	Metáfora
Data Engineer	Construir y mantener la infraestructura de datos.	Diseñar y optimizar bases de datos, crear pipelines ETL/ELT, asegurar la calidad de datos.	SQL, Python/Java/Scala, Bases de Datos (SQL/NoSQL), Big Data (Hadoop, Spark), Cloud.	El Arquitecto y Fontanero que construye las tuberías de datos.
Data Analyst	Interpretar datos históricos para insights de negocio.	Limpiar y preprocesar datos, análisis descriptivo, crear informes y dashboards, visualización.	SQL, Herramientas BI (Tableau, Power BI), Excel, Estadística Descriptiva, Comunicación.	El Periodista de Datos que explica lo que pasó y por qué.
Data Scientist	Construir modelos predictivos y prescriptivos.	Definir problemas de negocio, EDA, ingeniería de características, construir y validar modelos ML.	Matemáticas, Estadística, Python/R, Machine Learning, Conocimiento de Negocio, Comunicación.	El Científico y Meteorólogo que predice el futuro y aconseja.
ML Engineer	Poner modelos ML en producción y optimizarlos.	Desplegar modelos en sistemas, construir pipelines MLOps, monitorear y optimizar el rendimiento.	Ingeniería de Software, Python, Sistemas Distribuidos, MLOps (Docker, Kubernetes), Frameworks ML.	El Ingeniero de Sistemas que hace que las predicciones sean operativas.



Fuente: <https://iabac.org/blog/demystifying-the-data-science-process>

Roles Adicionales del Científico de Datos

Rol	Enfoque Principal	Responsabilidades Clave	Habilidades Típicas	Metáfora
Analytics Engineer	Preparar y modelar datos para el consumo de análisis.	Crear modelos de datos transformados, optimizar consultas, asegurar la calidad del modelo para BI.	SQL, herramientas de modelado de datos (dbt), Bases de Datos en la Nube, Python básico.	El Chef de Prep. de Alimentos: Toma los ingredientes crudos y los prepara, corta y organiza para que los cocineros (analistas) puedan usarlos fácilmente.
Data Product Manager	Definir y priorizar productos de datos que generen valor.	Investigar necesidades de negocio, definir visión del producto de datos, gestionar el backlog.	Conocimiento de Negocio, Gestión de Proyectos, Comunicación, Visión de Producto.	El Arquitecto de Productos Digitales: Diseña y asegura que el "edificio" (producto de datos) satisfaga las necesidades de los futuros inquilinos.
Machine Learning Researcher	Avanzar el estado del arte en ML y Deep Learning.	Investigar nuevos algoritmos y arquitecturas, publicar trabajos, contribuir al conocimiento.	PhD, Matemáticas, Estadística, Algoritmos ML, Programación (PyTorch, TensorFlow).	El Científico de Laboratorio: Busca nuevos descubrimientos y desarrolla nuevas teorías o tecnologías que otros aplicarán más tarde.
AI Ethicist / Responsible AI Specialist	Asegurar que la IA sea justa, transparente y responsable.	Auditar modelos por sesgos, desarrollar marcos de gobernanza, asesorar sobre ética y privacidad.	Ética, Leyes de Datos, Conocimiento de IA/ML, Comunicación, Pensamiento Crítico.	El Guardián de la Moral y la Justicia: Se asegura de que la "magia" de la IA sea usada para el bien y no tenga efectos secundarios negativos.
Business Intelligence Developer	Diseñar y construir soluciones de reportes y dashboards.	Diseñar Data Warehouses, crear ETLs para BI, construir informes y paneles interactivos.	SQL, Herramientas BI (Tableau, Power BI), Modelado de Datos, ETL.	El Cartógrafo y Presentador de Noticias: Transforma grandes cantidades de información en mapas claros (dashboards) y resúmenes noticiosos (reportes).



Fuente: <https://itbs.tn/master-data-science-business-analytics/>

Ciencia de datos vs Minería de Datos vs Big Data

	Big Data	Minería de Datos	Ciencia de Datos
Enfoque Principal	Almacenamiento y procesamiento de datos masivos (las 3 Vs).	Descubrimiento de patrones ocultos en los datos.	Ciclo completo para extraer conocimiento y valor accionable de los datos.
Naturaleza	Un fenómeno o conjunto de tecnologías.	Un conjunto de técnicas y algoritmos.	Una disciplina interdisciplinaria.
Pregunta Clave	¿Cómo manejamos/almacenamos estos datos?	¿Qué patrones puedo encontrar en estos datos?	¿Qué preguntas de negocio podemos responder con estos datos y cómo obtenemos valor?
Herramientas Típicas	Hadoop, Spark, NoSQL, sistemas distribuidos.	Algoritmos de ML, herramientas estadísticas.	Python, R, SQL, herramientas de Big Data, Machine Learning, visualización, conocimiento de negocio.
Relación	Provee los datos.	Utiliza los datos del Big Data para encontrar patrones.	Engloba a ambos, usando sus herramientas y técnicas para resolver problemas complejos.
Analogía	Piensa en el Big Data como la cantera o la mina gigantesca de donde provienen los minerales (los datos), y la maquinaria pesada para excavarlos y transportarlos.	Si Big Data es la mina, la Minería de Datos es la acción de excavar y tamizar esos minerales, usando herramientas específicas para encontrar las gemas valiosas (los patrones y conocimientos) dentro de la roca bruta.	La Ciencia de Datos es el equipo completo de geólogos, ingenieros y economistas que no solo gestiona la mina (Big Data) y excava (Minería de Datos), sino que también decide dónde excavar, qué buscar, cómo procesar las gemas encontradas y, lo más importante, cómo venderlas o utilizarlas para generar un valor real en el mercado.