

Presentación del Curso

Fundamentos de Ciencia de Datos

Germán A. Montoya O.
gamontoyao@eafit.edu.co

Universidad EAFIT

Medellín 2026

Información del Docente

- **Docente:** Germán A. Montoya O.
 - Encargado de la clase magistral y sus actividades.
 - **Formación:**
 - Ing. Electrónico: Universidad Pontificia Bolivariana
 - Ph.D en Ingeniería: Universidad de Los Andes.
 - **Intereses:** Modelos Matemáticos de Optimización, Simulación, Aprendizaje Automático, redes de sensores inalámbricos.
 - **Correo:** gamontoyao@eafit.edu.co
 - **Oficina:** 602 Bloque 19.

Información del Curso

- **Horario de Clases:**

- Viernes: 5pm – 9pm Aula 201 Bloque 35.
 - Receso de 7:30pm a 7:50pm.
- Sábados: 8am – 12pm Aula 201 Bloque 35.
 - Receso de 9:30am a 9:50am.

- **Días del curso:**

- Viernes y sábado: 17 y 18 de Julio respectivamente.
- Viernes y sábado: 24 y 25 de Julio respectivamente.
- Viernes y sábado: 31 de Julio y 01 de Agosto.

Metodología de la Clases

- **Aprendizaje experiencial:**

- El estudiante se encuentra en el centro del aprendizaje.
- El estudiante refuerza los conceptos implementando soluciones.

- **Rol del docente:**

- Impartir los conceptos principales sobre un tema.
- Guiar a los estudiantes para poner en práctica los conceptos impartidos.
- Guiar a los estudiantes para que resuelvan los problemas por ellos mismos.

Metodología de la Clases

- **Rol de los estudiantes:**

- Participar activamente en las sesiones presenciales y prácticas.
- Contribuir de manera ética y responsable al trabajo en equipo.
- Tener una actitud proactiva y recursiva para resolver las actividades del curso.

Metodología de la Clases

- **Dinámica de la clase:**

- **Paso 1:** El docente imparte 2 o 3 conceptos.
- **Paso 2:** Los estudiantes ponen en práctica dichos conceptos resolviendo distintos tipos de actividades. Al finalizar este paso, volvemos al paso 1.

Metodología de la Clases

- **Actividades por fuera de clase:**
 - Estudiar/repasar el material visto en clase.
 - Estudiar/repasar los códigos vistos en clase.
 - Trabajar en las diversas actividades del curso: talleres, entregas de proyectos, preparación de exámenes, entre otros.

Reglas en el aula de clases

- Preguntas cortas se responden inmediatamente en la clase.
- Preguntas que requieran mucho tiempo para responderse se resuelven en los espacios de actividades de la clase.
- Conservar el silencio cuando alguien este exponiéndole a todos un tema.

Objetivo General del Curso

- Comprender de manera integral la ciencia de datos, abarcando desde su contexto histórico, definición y naturaleza interdisciplinaria, hasta el **entendimiento profundo del ciclo de vida de un proyecto** y los diversos roles involucrados. Asimismo, desarrollar habilidades prácticas fundamentales en la **adquisición y el análisis exploratorio de distintos tipos de datos**, con el fin de **transformar datos crudos en activos de información valiosos, capaces de resolver problemas complejos mediante un enfoque analítico, ético y rigurosamente validado.**

Objetivos Específicos del Curso

- Comprender el contexto histórico, su definición, alcance y la naturaleza interdisciplinaria de la ciencia de datos.
- Entender el ciclo de vida de un proyecto de ciencia de datos, así como los roles del científico de datos.
- Comprender e implementar los fundamentos para realizar adquisición de datos.
- Desarrollar análisis exploratorio de datos para distintos tipos de datos.

Contenido General del Curso

- **Unidad 1: Introducción y Ciclo de Vida de la Ciencia de Datos**
 - Definición, alcance y naturaleza Interdisciplinaria
 - Evolución histórica y proyección futura.
 - Ciclos de vida: CRISP-DM, OSEMN, KDD y metodologías ágiles.
 - Roles y Competencias del científico de datos (Data Scientist, Data Engineer, ML Engineer, etc)
 - Diferencias entre Ciencia de Datos, Minería de Datos y Big Data.

Contenido General del Curso

- **Unidad 1.5: Repaso de Programación en Python y Pandas.**
 - Fundamentos de Python, NumPy y Pandas.
 - Visualización.
- **Unidad 2: Fundamentos y Adquisición de datos**
 - Tipos de datos (estructurados, semiestructurados y no estructurados).
 - Carga y adquisición básica de datos (CSV, excel, JSON)
 - Fuentes de Datasets Abiertas (Kaggle, IEEE Dataport, etc)
 - Competencias
 - Bases de datos
 - Web Scrapping, consumo de APIs y OCR

Contenido General del Curso

- **Unidad 2: Fundamentos y Adquisición de datos (cont.)**
 - Limpieza, validación y preprocesamiento de datos.
 - Manejo de valores faltantes, duplicados, inconsistencias, validación lógica, reorganización de columnas, entre otros.
 - Ingeniería de características y transformación de variables.
 - Escalamiento
 - Normalización
 - Correlación
 - Eliminación de columnas
 - Transformaciones logarítmicas
 - One-Hot encoding

Contenido General del Curso

- **Unidad 3: Análisis exploratorio de datos (EDA)**

- Estadística descriptiva (medidas de tendencia central, dispersión y posición).
- Manejo de valores atípicos.
- Visualización y Analisis Exploratorio de datos
 - Manejo de distintos tipos de Graficos (dispersión, calor, radar, series de tiempo, entre otros.)
 - Histogramas
- Herramientas automáticas de análisis exploratorio.

Motivación del Curso


- **Alfabetización de Datos (Data Literacy) de Alto Nivel:** En un mundo saturado de información, la motivación principal es desarrollar la capacidad de "leer" los datos, entendiendo no solo lo que dicen, sino lo que ocultan (sesgos, errores de recolección o vacíos estadísticos).
- **Eficiencia en el Ciclo de Vida del Proyecto:** Se estima que **un científico de datos pasa el 80% de su tiempo limpiando y preparando datos**. Este curso motiva el dominio de técnicas de Manipulación de Datos y EDA para que ese proceso sea eficiente, riguroso y no propenso a errores que perjudiquen modelos futuros.



Fuente: <https://www.usdsi.org/data-science-insights/data-structures-and-algorithms-infographic>

Motivación del Curso

- **Versatilidad Interdisciplinaria:** La ciencia de datos no es exclusiva de la tecnología; se aplica a la medicina, finanzas, ciencias sociales y más. Este curso motiva la creación de un lenguaje común que permite al estudiante colaborar con expertos de cualquier dominio.
- **Preparación para la Complejidad:** Antes de saltar a Deep Learning o IA Generativa, es vital entender los fundamentos. La motivación es construir una base sólida para que el estudiante no dependa de "recetas de cocina", sino que entienda la lógica subyacente y pueda adaptarse a las tecnologías que surjan en los próximos 10 años.



Fuente: <https://www.geeksforgeeks.org/dsa/10-most-important-data-structures-for-coding-interviews/>

Evaluación

- La evaluación del curso se estructura en cuatro (4) bloques equivalentes, cada uno con un peso del 25 % de la nota final:

Bloque de evaluación	Porcentaje
Bloque 1: Fundamentos y ciclo de vida de Ciencia de Datos	25 %
Bloque 2: Adquisición, limpieza y gestión de datos	25 %
Bloque 3: Análisis exploratorio y visualización	25 %
Bloque 4: Proyecto integrador aplicado	25 %

- Cada bloque podrá incluir actividades teórico-prácticas, talleres, informes y sustentaciones.

Evaluación

- Trabajo en parejas o equipos de hasta tres integrantes.
 - Evaluación grupal con seguimiento del aporte individual.
- Uso obligatorio de Python como lenguaje principal.
- La nota mínima aprobatoria del curso es 3.5.
- **Las entregas de las actividades deben ser subidas a Interactiva.**
 - No se reciben entregas por correo.
 - Las entregas no se reciben tarde.

Uso de Inteligencia Artificial

- El uso de herramientas de Inteligencia Artificial Generativa está permitido como apoyo al aprendizaje, siempre que se realice de forma ética, transparente y responsable.
- Los estudiantes deberán:
 - Declarar explícitamente el uso de herramientas de IA en cada entrega.
 - Utilizar la IA como apoyo y no como sustituto del razonamiento propio.
 - Asumir plena responsabilidad sobre el contenido entregado.
- El uso indebido de IA, incluyendo plagio o dependencia total de la herramienta, será considerado una falta a la integridad académica y tratado conforme al reglamento institucional.


Herramientas a usar

- Python en Google Colab o en un ambiente de desarrollo local (Anaconda, Pycharm, entre otros).
 - Traer equipo de computo si va a trabajar en ambiente desarrollo local.
- Librerías: Numpy, Pandas, Matplotlib, entre otras.

Herramientas a usar

- **Es muy importante que el estudiante implemente los pseudocódigos del curso.**
 - Aprende implementando.
 - Enriquece su portafolio en Github.
 - <https://github.com/>
 - Permite ser atractivo laboralmente o para optar por proyectos.

3,307 contributions in the last year



Fuente: <https://medium.com/mop-developers/the-subtle-discipline-of-daily-commits-f91136f0ed01>

Horario de Atención

- Cualquier inquietud la pueden consultar por las siguientes vías:
 - **En la clase magistral.**
 - **A través del correo electrónico:**
gamontoyao@eafit.edu.co
 - **En la oficina 602 bloque 19:** de Lunes a Miércoles de 10am a 12pm.
 - **A través de una reunión virtual:** El día y la hora de la reunión se establece por medio del correo electrónico.

Integridad Académica

- Como en todos los cursos de la Universidad EAFIT, se espera que el estudiante mantenga un alto nivel de ética así como de integridad en el desarrollo del curso.
 - Esto implica que todo trabajo sometido a evaluación es el resultado de su esfuerzo y dedicación.
 - Cualquier violación del código de integridad académica, va a ser evaluado y sancionado acorde a lo establecido en los estatutos de la Universidad EAFIT, teniendo como consecuencias las sanciones disciplinarias establecidas para esto.

Actividad: presentación de los estudiantes

- Formar grupos de 3 personas.
- Conocerse e intercambiar experiencias académicas o laborales relacionadas con Ciencia de Datos.
- Duración de la actividad: 15 a 20 minutos.